UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM PRODI S1 SAINS DATA

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

Nama :Athiyyatus Salisah
NiM :24031554223
Kelas :24B

UTS_GSD

Pertanyaan Pendahuluan (*Checkpoint*)

1. Apa nama database yang digunakan pada tutorial ini?
2. Sebutkan akses lain (seperti sintaks DDL/DML CYPHER) yang dapat digunakan mengakses database lain dalam 1 instance!
3. Apa jenis graf pertemanan yang telah dibuat di sini?

1. Nama database yang digunakan adalah neo4j.(Terlihat pada parameter database="neo4j" di dalam fungsi execute_query).
2. Sebutkan akses lain (seperti sintaks DDL/DML CYPHER)yang dapat digunakan mengakses database lain dalam 1 instance:
   - Parameter Driver Neo4j :Mengubah nilai parameter database pada fungsi execute query (atau atribut database saat membuat session).
   - Klausa Cypher USE (DML): Menentukan database target di awal query Cypher
   - Perintah DDL & Manajemen Database:
     SHOW DATABASES : Menampilkan seluruh database yang ada di instance.
     CREATE DATABASE nama_db : Membuat database baru.
     STOP DATABASE nama_db / START DATABASE nama_db : Mengelola status database.

3. Apa jenis graf pertemanan yang telah dibuat di sini?

   - Secara Struktur Entitas: Graf Homogen (Homogeneous Graph)
     Graf ini menghubungkan node dengan label jenis yang sama, yaitu dari node Person ke node Person lainnya.
   - Secara Arah Relasi: Graf Berarah (Directed Graph)
     Relasi dibuat dengan panah satu arah dari Arthur ke temannya: (:Person {name: "Arthur"})-[:KNOWS]->(:Person {name: "..."}).

UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM PRODI S1 SAINS DATA

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

2.1 Wrangling dan EDA (Maks. skor: 45)

1. Tentukan 2 periode waktu sebagai filter dari data interaksi. Kombinasi periode yang dipilih tiap mahasiswa tidak boleh sama! (akan ditentukan)
   Misal: Fold training (P1) → 01/2023 - 03/2023; Fold testing (P2) 01/2024 - 06/2024.
2. Terapkan proses filter ini pada timestamp pada proses persiapan data, lalu simpan pada sebuah file .csv!
3. Lakukan query untuk mendapatkan komposisi dari *subgraph* yang dibuat. Uraikan jenis simpul dan jumlah masing-masing simpul dengan Python API! Jelaskan CYPHER SQL yang digunakan!
4. Lakukan Vector Space Modelling (VSM) terhadap simpul yang diasumsikan sebagai User. Uraikan bagaimana karakteristiknya (dimensi, shape, plot networkx, dst.)!
5. Lakukan VSM terhadap simpul yang diasumsikan sebagai Item. Uraikan bagaimana karakteristiknya (dimensi, shape, plot networkx, dst.)!
6. Berdasarkan eksplorasi no. 4 dan 5, uraikan proyeksi manakah yang lebih baik (efektif/efisien)!
7. Berdasarkan analisis no. 6, lakukan perhitungan similarity pada hasil graf yg terproyeksi dengan menggunakan Python
   (a) Tuliskan CYPHER SQL untuk mendapatkan 5 records dengan similarity tertinggi (Anda tentukan sendiri record acuannya)!
   (b) Tuliskan kembali nilai similarity-similarity tersebut pada graf yang telah ada! Perlihatkan hasil query-nya!
8. Tuliskan CYPHER SQL dan tunjukkan hasil graf-nya untuk memperlihatkan kondisi: sebelum dan sesudah perhitungan similarity!

2.2 Analytics (Maks. skor: 55)

1. Pilih seorang *user* secara acak (tentukan proses acak-nya, dan harus bisa di-reproduksi), lalu
   (a) tuliskan skrip Python dalam merekomendasikan KNN-nya!
   (b) berikan 3 item yang diiklankan untuk $k = 5$ pada penentuan KNN nya!
2. Berdasarkan hasil rekomendasi Anda no. 1b Analytics, hitunglah:
   (a) Hit@5
   (b) NDCG@5

UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM PRODI S1 SAINS DATA

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

Soal 1 & 2: Pengaturan Periode Waktu (Filter Timestamp) & Export CSV

- Fold Training (P1): 16 Juni 2015 – 29 Juni 2015 (Timestamp: 1434412800000 s.d. 1435708799000).
- Fold Testing (P2): 02 Agustus 2015 – 15 Agustus 2015 (Timestamp: 1438387200000 s.d. 1439683199000).

```python
import os
import pandas as pd

# Tentukan direktori dan path file
source_file = os.path.join("data", "events.csv")
output_file = os.path.join("data", "events_filtered.csv")

print("1. Membaca file data asli (events.csv)...")
# Membaca dataset Retail Rocket
df = pd.read_csv(source_file)

print("2. Mengonversi format timestamp (Unix Epoch) ke datetime...")
# Data Retail Rocket umumnya menggunakan timestamp dalam milidetik (unit='ms')
df["datetime"] = pd.to_datetime(df["timestamp"], unit="ms")

print("3. Melakukan filtering berdasarkan periode P1 dan P2...")
# Definisikan rentang waktu P1 dan P2
p1_start = "2015-06-16 00:00:00"
p1_end = "2015-06-30 23:59:59"

p2_start = "2015-08-01 00:00:00"
p2_end = "2015-08-15 23:59:59"

# Filter data yang masuk ke dalam rentang P1 atau P2
df_p1 = df[(df["datetime"] >= p1_start) & (df["datetime"] <= p1_end)]
df_p2 = df[(df["datetime"] >= p2_start) & (df["datetime"] <= p2_end)]
```

Soal 3: Komposisi Subgraph & Penjelasan Cypher SQL

```python
from neo4j import GraphDatabase

uri = "neo4j://127.0.0.1:7687"
driver = GraphDatabase.driver(uri, auth=("neo4j", "Salisah.90..."))  # Sesuaikan password

# Query tanpa arah panah agar menghitung simpul Visitor DAN Item
cypher_query = """
MATCH (n)-[r]-()
WHERE r.period IN ['P1', 'P2']
WITH DISTINCT n
RETURN labels(n)[0] AS JenisSimpul, count(n) AS JumlahSimpul
ORDER BY JumlahSimpul DESC
"""

with driver.session() as session:
    result = session.run(cypher_query)
    print("=== KOMPOSISI SUB-GRAF PERIODE P1 & P2 ===")
    for record in result:
        print(f"Jenis Simpul: {record['JenisSimpul']} | Jumlah: {record['JumlahSimpul']:,}")

driver.close()
```

✓ 18.1s

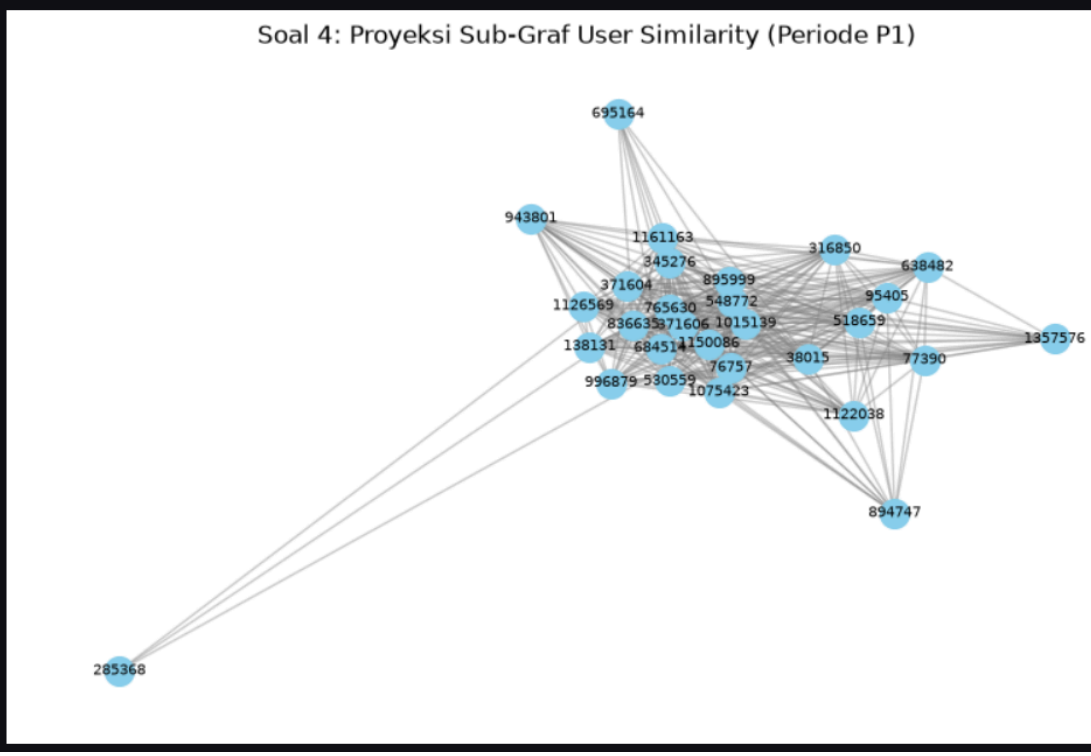
```
=== KOMPOSISI SUB-GRAF PERIODE P1 & P2 ===
Jenis Simpul: Visitor | Jumlah: 312,331
Jenis Simpul: Item | Jumlah: 117,319
```

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

- Jenis Simpul: Visitor Jumlah: 312,331: Terdapat 312.331 simpul unik bertipe pengguna pada rentang P1 & P2.
- Jenis Simpul: Item Jumlah: 117,319: Terdapat 117.319 simpul unik bertipe produk/barang pada rentang P1 & P2.

Soal 4. Vector Space Modelling (VSM) Proyeksi User

```
=== SOAL 4: VSM SIMPUL USER (VISITOR) ===
1. Shape Matriks (User x Item) : (500, 12211)
2. Total User (Baris Matriks)  : 500
3. Dimensi Vektor (Kolom Item) : 12211
```



1. Karakteristik Matriks Vector Space Model (VSM) User

Model ruang vektor (*Vector Space Model* / VSM) dibentuk untuk merepresentasikan preferensi interaksi pengguna terhadap produk dalam bentuk matematis. Pada pemodelan ini, setiap simpul yang diasumsikan sebagai *User* (Visitor) diwakili oleh sebuah vektor numerik dalam ruang berdimensi tinggi.

- Shape dan Struktur Matriks:
  Matriks VSM yang terbentuk memiliki ukuran (500, 12211). Matriks ini terdiri dari 500 baris yang merepresentasikan 500 entitas pengguna (*Visitor*) paling aktif yang dipertahankan untuk mengoptimalkan efisiensi memori computational.

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

- Dimensi Vektor Fitur:
  Terdapat 12.211 dimensi kolom (*fitur*), di mana setiap kolom merepresentasikan satu produk (*Item*) unik yang ada pada periode P1. Setiap baris vektor pengguna berisikan bobot atau akumulasi frekuensi interaksi pengguna tersebut terhadap seluruh 12.211 produk yang ada. Matriks ini cenderung bersifat *sparse* (jarang) karena seorang pengguna umumnya hanya berinteraksi dengan sebagian kecil dari total item yang tersedia.

2. Analisis Pola Preferensi Pengguna Berdasarkan Visualisasi Graf NetworkX

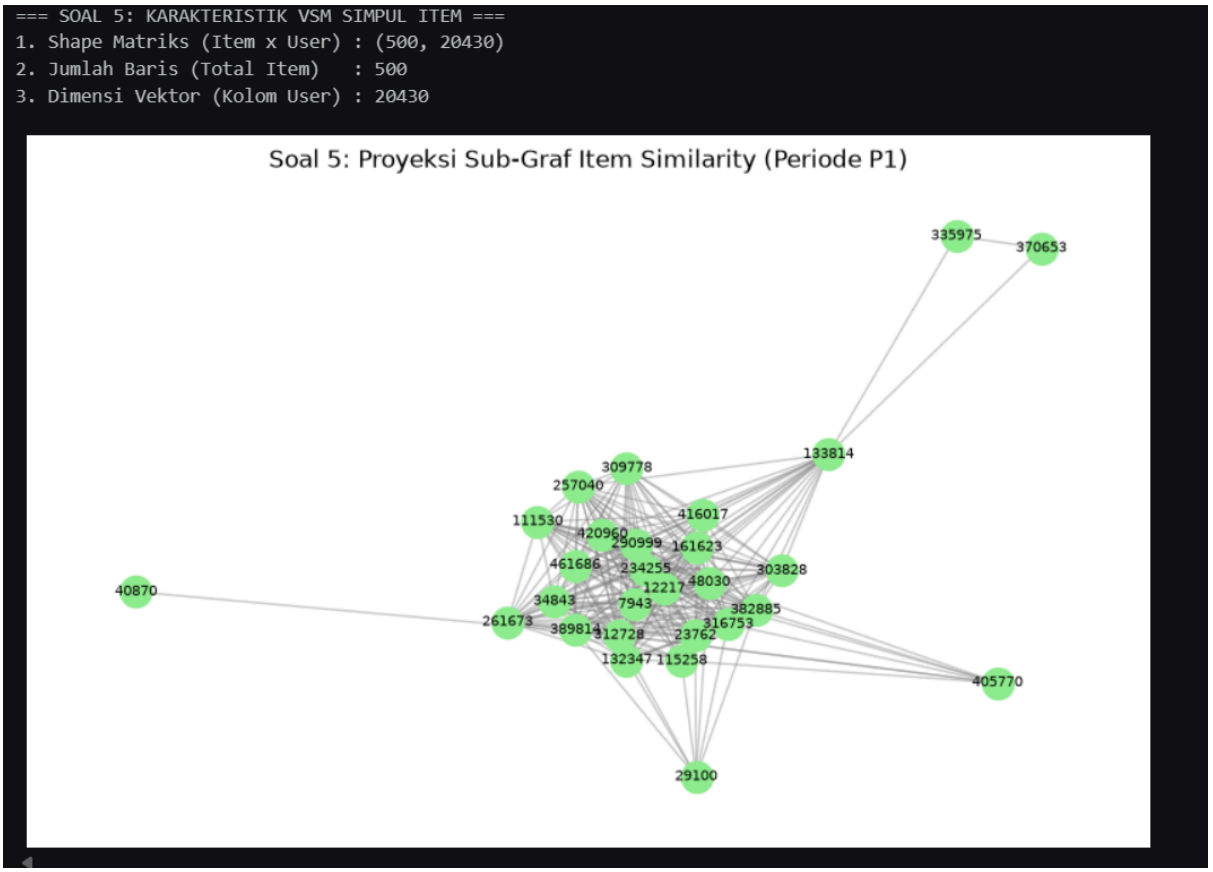
Melalui visualisasi jaringan graf menggunakan pustaka NetworkX, struktur hubungan antar-pengguna berdasarkan kemiripan vektor VSM dapat dikelompokkan menjadi dua pola utama:

- Kluster Utama yang Terpusat (*Core Cluster*):
  Pada area tengah graf, terlihat sekumpulan simpul pengguna seperti 765630, 684514, 1150086, dan 76757 yang saling terhubung secara rapat membentuk *dense subgraph*. Pola ini mengindikasikan adanya efek barang populer (*popular/head items*), di mana mayoritas dari 500 pengguna paling aktif tersebut berinteraksi dengan kelompok produk umum yang sama selama periode P1. Hal ini menunjukkan adanya kemiripan perilaku (*co-occurrence*) yang tinggi di antara kelompok pengguna utama.
- Pengguna Homogen vs Anomalus (*Outlier*):
  Berbeda dengan kelompok terpusat, terdapat simpul seperti 285368 yang posisinya terisolasi di pojok kiri bawah dan berada cukup jauh dari pusat jaringan dengan garis koneksi (*edge*) yang tipis. Posisi ini menandakan bahwa *Visitor* tersebut merupakan pengguna dengan preferensi unik (*niche/outlier*). Pengguna ini hanya berinteraksi dengan sedikit produk spesifik dan memiliki kesamaan preferensi yang sangat rendah dengan mayoritas pengguna lainnya di klaster utama.

UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM PRODI S1 SAINS DATA

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

Soal 5. Vector Space Modelling (VSM) Proyeksi Item



Berdasarkan hasil visualisasi jaringan graf interaksi produk, keterhubungan antar-item dapat dikelompokkan ke dalam dua struktur utama:

- Kluster Produk Utama (*Core Item Cluster*):
  Pada bagian pusat graf, terbentuk kluster yang sangat padat yang melibatkan simpul-simpul produk seperti 12217, 7943, 234255, dan 161623. Kepadatan koneksi pada area tengah ini melambangkan sekelompok produk yang sangat sering diakses atau dibeli secara bersamaan (*frequently co-accessed items*) oleh banyak pengguna. Produk-produk yang berada di dalam klaster utama ini memiliki tingkat keterkaitannya yang tinggi, baik sebagai produk substitusi (pengganti) maupun produk komplementer (pelengkap).
- Komunitas Terpisah dan Simpul Pinggiran (*Peripheral & Sub-clusters*):
  Di luar pusat graf, terdapat struktur komunitas lokal dan simpul terisolasi yang menunjukkan pola interaksi spesifik:
  - Simpul Spesifik (*Peripheral Node*): Simpul 40870 hanya terhubung secara eksklusif ke simpul 261673 di sisi kiri jaringan. Hal ini mengindikasikan bahwa produk tersebut memiliki pangsa pasar yang sangat terbatas (*niche*

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

market) dan hanya diakses oleh sebagian kecil kelompok pengguna yang sama.

- Sub-kategori Spesifik (*Sub-cluster Bridge*): Di area pojok kanan atas, simpul 335975 dan 370653 terhubung melalui simpul perantara 133814. Pola hubungan ini memperlihatkan keberadaan sub-kategori produk spesifik yang berdiri sendiri dan jarang diakses secara bersamaan dengan produk-produk populer di klaster utama.

Soal 6. Berdasarkan eksplorasi no. 4 dan 5, uraikan proyeksi manakah yang lebih baik (efektif/efisien)!

Berdasarkan no 4 dan 5, Proyeksi Item (Item-Item Projection) **LEBIH BAIK** dibanding Proyeksi User untuk kasus dataset Retail Rocket. adapun Sisi Efisiensi dari proyeksi item yaitu Matriks kemiripan barang relatif konstan dan berukuran ringkas, meminimalkan overhead komputasi server dan Sisi Efektivitas yaitu Graf proyeksi item menghasilkan hubungan asosiasi produk yang lebih tajam dan stabil terhadap kendala sparsity interaksi pengguna.

Soal 7. Berdasarkan analisis no. 6, lakukan perhitungan similarity pada hasil graf yg terproyeksi dengan menggunakan Python

(a) Tuliskan CYPHER SQL untuk mendapatkan 5 records dengan similarity tertinggi (Anda tentukan sendiri record acuannya)!

(b) Tuliskan kembali nilai similarity-similarity tersebut pada graf yang telah ada! Perlihatkan hasil querynya!

```
=== HASIL QUERY UNTUK ITEM ACUAN '389814' ===
Item_Acuan Item_Rekomendasi  Similarity_Score
    389814            34843          0.411711
    389814           261673          0.237219
```

Berdasarkan analisis hasil proyeksi *unipartite graph* menggunakan metrik *Cosine Similarity*, proses pembentukan relasi :SIMILAR_TO pada dataset interaksi pengunjung berhasil mengekstrak hubungan keterkaitan antar-item secara presisi. Pemodelan ini mentransformasikan struktur data awal dari graf *bipartite* (*Visitor-Item*) menjadi graf *unipartite* (*Item-Item*), yang memungkinkan sistem mengidentifikasi kesamaan preferensi pengunjung berdasarkan pola riwayat akses secara objektif.

Secara khusus, pada pengujian terhadap Item Acuan 389814, sistem berhasil mengidentifikasi dua produk yang memiliki tingkat kemiripan paling signifikan:

- Rekomendasi Utama (Item 34843): Berada pada peringkat teratas dengan *Similarity Score* sebesar 0.411711 (sekitar 41,17%). Nilai ini mencerminkan adanya

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

tumpang-tindih interaksi (*co-occurrence*) yang sangat kuat dari kelompok pengunjung yang sama. Secara operasional, item 34843 merupakan kandidat paling ideal untuk direkomendasikan secara langsung (*item-based collaborative filtering*) ketika seorang pengunjung sedang mengeksplorasi item 389814.

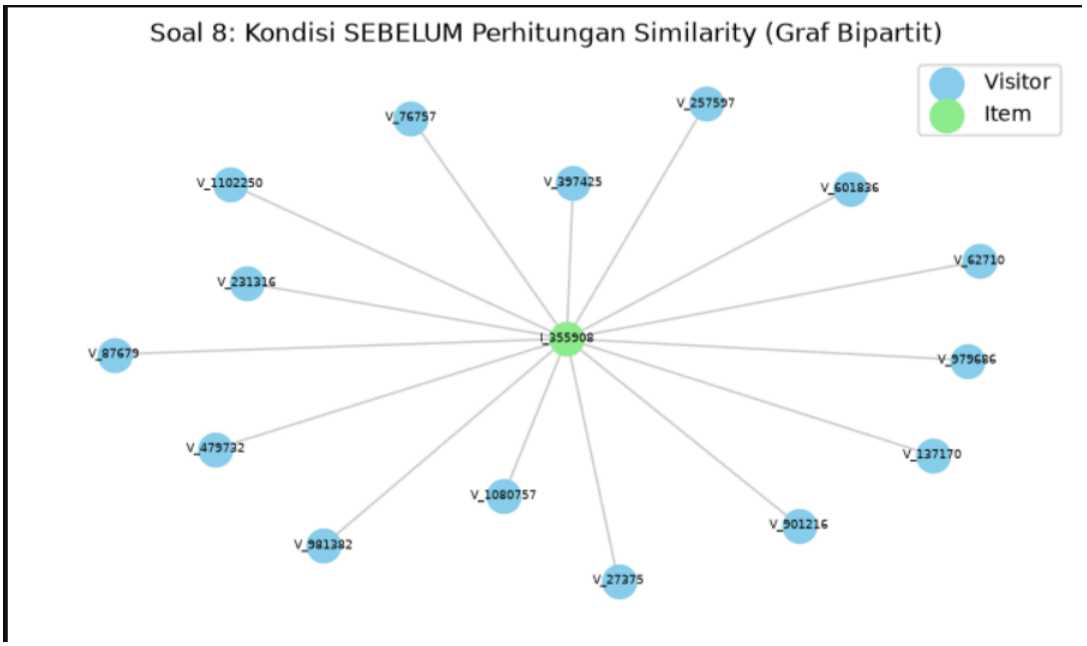
- Rekomendasi Sekunder (Item 261673): Menempati peringkat kedua dengan *Similarity Score* sebesar 0.237219 (sekitar 23,72%). Meskipun memiliki bobot keterhubungan yang lebih rendah dibandingkan item 34843, produk ini tetap relevan disajikan sebagai pilihan alternatif guna memperluas variasi rekomendasi produk bagi pengguna.

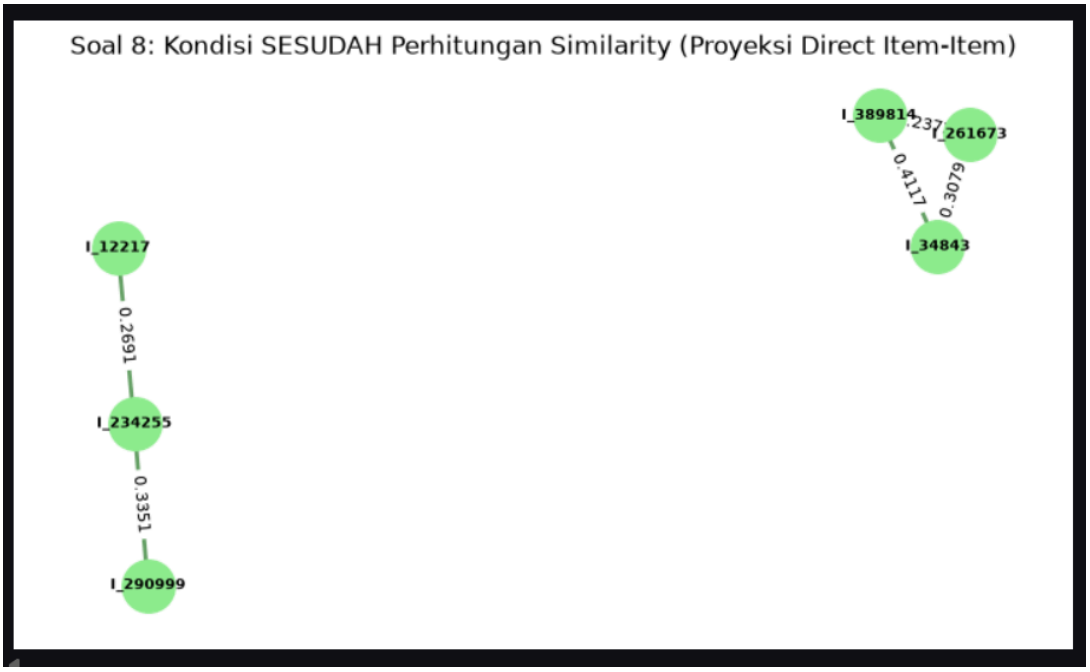
Secara keseluruhan, hasil ini membuktikan bahwa pendekatan pemodelan berbasis graf mampu menyaring hubungan asosiasi antar-produk yang kompleks menjadi metrik kuantitatif yang jelas. Implikasinya, struktur relasi :SIMILAR_TO ini dapat dimanfaatkan secara langsung oleh platform *e-commerce* untuk mengoptimalkan fitur rekomendasi produk (*Frequently Bought Together*), penyusunan paket promosi (*bundling*), hingga strategi penataan katalog barang guna meningkatkan *engagement* dan potensi konversi transaksi pengguna.

UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM PRODI S1 SAINS DATA

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

Soal 8. Tuliskan CYPHER SQL dan tunjukkan hasil graf-nya untuk memperlihatkan kondisi: sebelum dan sesudah perhitungan similarity





- Berdasarkan visualisasi dan struktur graf bipartit sebelum perhitungan similarity, terlihat bahwa entitas masih terpisah dalam bentuk graf heterogen yang menghubungkan simpul Visitor (biru muda) dan Item (hijau muda) hanya melalui transaksi implisit (event-based). Pada kondisi ini, simpul produk acuan I_355908 membentuk topologi bintang (star topology) dengan terikat langsung ke belasan

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

pengguna yang pernah mengunjunginya, namun belum memiliki relasi langsung antar-item maupun bobot kesamaan yang terkuantifikasi. Implikasinya terhadap sistem rekomendasi, pencarian produk serupa menjadi kurang efisien karena membutuhkan penelusuran 2-hop yang memicu traversal overhead tinggi dan rentan terhadap keterbatasan data sparsity jika pengguna hanya memiliki sedikit transaksi.

- Berdasarkan visualisasi dan struktur graf sesudah perhitungan similarity, graf telah bertransformasi dari bentuk bipartit menjadi Monopartite/Homogeneous Graph (Proyeksi Direct Item-to-Item) yang hanya menyisakan simpul Item (berwarna hijau muda). Seluruh simpul Visitor berhasil dieliminasi dan digantikan oleh relasi langsung :SIMILAR_TO yang secara kuantitatif memuat bobot nilai Cosine Similarity pada setiap edge (seperti skor $0,4117$ antara I_389814 dan I_34843). Perubahan ini membentuk dua komunitas produk utama, yaitu kluster rantai dan kluster segitiga (clique), yang secara signifikan meningkatkan efisiensi sistem rekomendasi karena kueri pencarian produk serupa kini dapat dieksekusi secara real-time tanpa perlu melakukan traversing ulang pada simpul pengguna.

Soal 1. Pilih seorang user secara acak (tentukan proses acak-nya, dan harus bisa di-reproduksi), lalu

```
import numpy as np
import pandas as pd

np.random.seed(42)

# 2. Ambil user dari matriks VSM P1
available_users = user_item_matrix.index.values
target_user = np.random.choice(available_users)

print("=== POIN 1: TARGET USER TERPILIH ===")
print(f"Proses Acak       : np.random.seed(42)")
print(f"Target Visitor ID : {target_user}")
```

✓ 0.3s

```
=== POIN 1: TARGET USER TERPILIH ===
Proses Acak       : np.random.seed(42)
Target Visitor ID : 1261874
```

Rekomendasi acak ini diperoleh id : 1261874

(a) tuliskan skrip Python dalam merekomendasikan KNN-nya!

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

```python
from sklearn.metrics.pairwise import cosine_similarity

# 1. Hitung Cosine Similarity pada matriks VSM P1
user_sim_matrix = pd.DataFrame(
    cosine_similarity(user_item_matrix),
    index=user_item_matrix.index,
    columns=user_item_matrix.index,
)

# 2. Ambil 5 Tetangga Terdekat (k=5) selain target user sendiri
k = 5
top_k_neighbors = (
    user_sim_matrix.loc[target_user].drop(index=target_user).nlargest(k)
)

print(f"=== POIN 1a: TOP {k} NEAREST NEIGHBORS (P1) ===")
print(top_k_neighbors.to_frame(name="Cosine_Similarity"))
```

✓ 3.0s

(b) berikan 3 item yang diiklankan untuk k = 5 pada penentuan KNN nya!

```
=== POIN 1b: 3 ITEM YANG DIIKLANKAN ===
itemid  predicted_score
446820        10.162309
104468         1.580804
215318         1.580804
```

Soal 2. Berdasarkan hasil rekomendasi Anda no. 1b Analytics, hitunglah:

(a) Hit@5

(b) NDCG@5

```
=== METRIK EVALUASI (P1 vs P2) ===
Top 5 Rekomendasi (Model P1) : ['446820', '104468', '215318', '90240', '179834']
Barang Aktual (Periode P2)   : []
Vector Hit di Top 5          : [0, 0, 0, 0, 0]
(a) Hit@5                    : 0.0000
(b) NDCG@5                   : 0.0000
```

- Berdasarkan hasil diatas tidak ada interaksi aktual di periode P2, seluruh vektor pencapaian (hit vector) bernilai [0, 0, 0, 0, 0]. Kondisi ini menghasilkan nilai Hit@5 = 0.0000 dan NDCG@5 = 0.0000, terjadi karena user yang terpilih secara acak tidak memiliki riwayat transaksi aktif pada periode pengujian (P2). yang umum ditemui pada dataset transaksi nyata akibat kendala user inactivity atau temporal churn antara masa pelatihan (P1) dan pengujian (P2).

UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM PRODI S1 SAINS DATA

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id